

UNIVERSIDAD SAN FRANCISCO DE QUITO USFQ

Colegio de Posgrados

Extracción de Reglas Interpretables mediante RuleCOSI+

Proyecto de Titulación

Danilo Fernando Serrano Enríquez

Edison Loza, Ph.D.

Director de Trabajo de Titulación

Trabajo de titulación de posgrado presentado como requisito
para la obtención del título de **Magíster en Ciencia de Datos**

Quito, 8 de julio de 2026

UNIVERSIDAD SAN FRANCISCO DE QUITO USFQ

COLEGIO DE POSGRADOS

HOJA DE APROBACIÓN DE TRABAJO DE TITULACIÓN

Extracción de Reglas Interpretables mediante RuleCOSI+

Danilo Fernando Serrano Enríquez

Nombre del Director del Programa:
Título académico:
Director del programa de:

Felipe Grijalva
Ph.D. en Ingeniería Eléctrica
Ciencia de Datos

Nombre del Decano del colegio Académico:
Título académico:
Decano del Colegio:

Eduardo Alba
Doctor en Ciencias Matemáticas
Ciencias e Ingenierías

Nombre del Decano del Colegio de Posgrados:
Título académico:

Dario Niebieskikwiat
Doctor en Física

Quito, 8 de julio de 2026

© DERECHOS DE AUTOR

Por medio del presente documento certifico que he leído todas las Políticas y Manuales de la Universidad San Francisco de Quito USFQ, incluyendo la Política de Propiedad Intelectual USFQ, y estoy de acuerdo con su contenido, por lo que los derechos de propiedad intelectual del presente trabajo quedan sujetos a lo dispuesto en esas Políticas.

Asimismo, autorizo a la USFQ para que realice la digitalización y publicación de este trabajo en el repositorio virtual, de conformidad a lo dispuesto en la Ley Orgánica de Educación Superior del Ecuador.

Nombre del estudiante: Danilo Fernando Serrano Enríquez

Código de estudiante: 00348320

C.I.: 1725349581

Lugar y fecha: Quito, 8 de julio de 2026

ACLARACIÓN PARA PUBLICACIÓN

Nota: El presente trabajo, en su totalidad o cualquiera de sus partes, no debe ser considerado como una publicación, incluso a pesar de estar disponible sin restricciones a través de un repositorio institucional. Esta declaración se alinea con las prácticas y recomendaciones presentadas por el Committee on Publication Ethics COPE descritas por Barbour et al. (2017) Discussion document on best practice for issues around theses publishing, disponible en <http://bit.ly/COPETheses>.

UNPUBLISHED DOCUMENT

Note: The following graduation project is available through Universidad San Francisco de Quito USFQ institutional repository. Nonetheless, this project – in whole or in part – should not be considered a publication. This statement follows the recommendations presented by the Committee on Publication Ethics COPE described by Barbour et al. (2017) Discussion document on best practice for issues around theses publishing available on <http://bit.ly/COPETheses>.

AGRADECIMIENTOS

Quiero expresar mi más sincero agradecimiento a mi esposa, Lia, por recorrer este camino a mi lado. Gracias por ser mi compañera de vida y de aventuras, por sostenerme en los momentos más difíciles, por celebrar conmigo cada pequeño avance y por creer en mí sin importar las dificultades que enfrentamos. Tu amor, paciencia y confianza fueron el impulso que muchas veces necesité para seguir adelante. Este logro también es tuyo.

A mis padres, gracias por su amor, por su confianza y por brindarme siempre el respaldo necesario para alcanzar mis metas. Saber que siempre conté con ustedes me dio la tranquilidad y la fortaleza para construir mi sueño. Gracias por acompañarme en este camino.

Finalmente, agradezco a todas las personas que, de una u otra manera, contribuyeron a este proceso con su apoyo, sus enseñanzas y sus palabras de aliento. Cada uno dejó una huella importante en este logro.

RESUMEN

El scoring crediticio es un proceso crítico en la industria financiera donde la tensión entre precisión predictiva e interpretabilidad de los modelos representa un desafío regulatorio de primer orden. Este trabajo propone el uso de RuleCOSI+ (Obregón & Jung, 2023) para comprimir un modelo CatBoost entrenado sobre el dataset público de LendingClub en un conjunto mínimo de reglas proposicionales interpretables, seleccionadas mediante análisis de frontera de Pareto. Como aporte metodológico central, se identifica y corrige una fuga de información presente en el trabajo previo de Jaramillo et al. (2024): la variable *recoveries*, de naturaleza post-hoc, se elimina antes de cualquier entrenamiento, reduciendo el F1-score de referencia de 0,8887 a 0,7740 y cuantificando en 0,1147 puntos el componente espurio introducido por dicha variable. La configuración Pareto-óptima seleccionada ($\alpha = 0,50$, $\beta = 0,01$, $c = 0,10$) produce cinco reglas crisp con $F1 = 0,7652$ y una Reducción de Reglas (REDU) de 0,9849, reteniendo el 98,9 % del rendimiento del CatBoost de referencia al comprimir 332 reglas activas a 5. Las reglas resultantes se expresan en términos de variables de scoring estándar —puntuaciones FICO, monto del préstamo e indicador de liquidación de deuda— y son directamente auditables bajo marcos regulatorios como Basilea III y el Reglamento de Inteligencia Artificial de la Unión Europea.

Palabras clave: scoring crediticio, RuleCOSI+, extracción de reglas, CatBoost, frontera de Pareto, interpretabilidad, fuga de información, reglas crisp, árboles de decisión, aprendizaje automático

ABSTRACT

Credit scoring is a critical process in the financial industry where the tension between predictive accuracy and model interpretability represents a first-order regulatory challenge. This work proposes the use of RuleCOSI+ (Obregón & Jung, 2023) to compress a CatBoost model trained on the public LendingClub dataset into a minimal set of interpretable propositional rules, selected through Pareto frontier analysis. As a central methodological contribution, a data leakage issue present in the prior work of Jaramillo et al. (2024) is identified and corrected: the *recoveries* variable, post-hoc in nature, is removed before any training step, reducing the reference F1-score from 0.8887 to 0.7740 and quantifying the spurious component at 0.1147 F1 points. The selected Pareto-optimal configuration ($\alpha = 0.50$, $\beta = 0.01$, $c = 0.10$) produces five crisp rules with $F1 = 0.7652$ and a Rule Reduction (REDU) of 0.9849, retaining 98.9% of the reference CatBoost performance by compressing 332 active rules to 5. The resulting rules are expressed in terms of standard scoring variables—FICO scores, loan amount, and debt settlement indicator—and are directly auditable under regulatory frameworks such as Basel III and the European Union Artificial Intelligence Act.

Keywords: credit scoring, RuleCOSI+, rule extraction, CatBoost, Pareto frontier, interpretability, data leakage, crisp rules, decision trees, machine learning

TABLA DE CONTENIDO

I	Introducción	11
II	Marco Teórico	12
II-A	Scoring Crediticio y Aprendizaje Automático	12
II-B	Árboles Oblivious y Reglas Crisp	12
II-C	RuleCOSI+	12
II-D	Sistemas de Inferencia Difusa	12
III	Descripción del Dataset y Preprocesamiento	13
III-A	Fuente de Datos	13
III-B	Preprocesamiento	13
III-C	Partición Anti-Leakage	13
IV	Metodología e Implementación	13
IV-A	Selección del Modelo Base	13
IV-B	Diseño del Grid de Hiperparámetros	13
IV-C	Escenarios de Evaluación	13
IV-D	Selección de la Configuración Óptima: Frontera de Pareto	14
IV-E	Traducción Conceptual a Términos Lingüísticos	14
IV-F	Implementación	14
V	Resultados y Discusión	14
V-A	Escenario A: Grid de Búsqueda con <i>recoveries</i>	14
V-B	Escenario B: Rendimiento del Modelo Base y Grid sin <i>recoveries</i>	14
V-C	Frontera de Pareto y Configuración Seleccionada	15
V-D	Discusión	16
VI	Conclusiones	17
	References	18

ÍNDICE DE TABLAS

I	Comparación de los modelos de ensemble candidatos.	13
II	Resultados representativos del grid de búsqueda en el Escenario A (con <i>recoveries</i>). . .	14
III	Rendimiento del modelo base CatBoost en el Escenario B (sin <i>recoveries</i>).	14
IV	Resultados representativos del grid de búsqueda en el Escenario B (sin <i>recoveries</i>). . . .	15
V	Puntos Pareto-óptimos en el espacio (n_reglas , $F1_test$).	16
VI	Comparación de enfoques: este trabajo frente a Jaramillo et al. (2024).	16

ÍNDICE DE FIGURAS

1	Reducción de reglas: CatBoost baseline (332 reglas) VS RuleCOSI+ con la configuración seleccionada (5 reglas).	15
2	Número de reglas por configuración del grid; verde = cumple umbral $F1 \geq 85\%$ del CatBoost.	15
3	Heatmap de métricas del grid de 24 configuraciones (Escenario B): número de reglas (izq.), F1-score en test (centro) y condiciones promedio por regla (der.), para cada combinación de α , β y c	15
4	Frontera de Pareto en el espacio $(n_reglas, F1_test)$. Los rombos rojos son los tres puntos Pareto-óptimos; los círculos azules son configuraciones no dominantes. P1 es el codo de la curva; P2 (5 reglas, $F1=0,7652$) es el punto seleccionado.	15

Extracción de Reglas Interprettables mediante RuleCOSI+

Danilo Fernando Serrano Enríquez

Abstract—Credit scoring is a critical process in the financial industry where the tension between predictive accuracy and model interpretability represents a first-order regulatory challenge. This work proposes the use of RuleCOSI+ (Obregón & Jung, 2023) to compress a CatBoost model trained on the public LendingClub dataset into a minimal set of interpretable propositional rules, selected through Pareto frontier analysis. A data leakage issue in the prior work of Jaramillo et al. (2024) is identified and corrected: the *recoveries* variable is removed before any training step, reducing the reference F1-score from 0.8887 to 0.7740. The selected Pareto-optimal configuration ($\alpha=0.50$, $\beta=0.01$, $c=0.10$) produces five crisp rules with $F1=0.7652$ and $REDU=0.9849$, retaining 98.9% of the reference CatBoost performance.

Index Terms—credit scoring, RuleCOSI+, rule extraction, CatBoost, Pareto frontier, interpretability, data leakage, crisp rules, decision trees, machine learning

I. INTRODUCCIÓN

EL scoring crediticio es uno de los procesos más críticos en la industria financiera (Thomas et al., 2017). Determinar con precisión si un solicitante pagará o no su obligación tiene implicaciones directas sobre la rentabilidad de las instituciones y el bienestar económico de sus clientes (Hand & Henley, 1997). Durante décadas, este proceso se apoyó en modelos estadísticos clásicos —regresión logística, análisis discriminante— que ofrecen resultados interpretables pero limitan la capacidad predictiva (Altman, 1968; Wiginton, 1980). En años recientes, el aprendizaje automático ha desplazado progresivamente esos métodos, alcanzando niveles de precisión que difícilmente se logran con modelos tradicionales (Lessmann et al., 2015; Gunnarsson et al., 2021).

Sin embargo, el auge de los modelos de aprendizaje automático no llega sin costo. Algoritmos como los árboles de decisión potenciados por gradiente (CatBoost, XGBoost, LightGBM) (Dorogush et al., 2018; Chen & Guestrin, 2016; Ke et al., 2017) funcionan como cajas negras: sus predicciones son difíciles de auditar, comunicar a reguladores y justificar ante clientes que solicitan explicación de una decisión adversa (Rudin, 2019). Este problema es especialmente relevante en el contexto regulatorio actual, donde marcos como Basilea III (Comité de Supervisión Bancaria de Basilea, 2017) y el Reglamento de Inteligencia

Artificial de la Unión Europea (Comisión Europea, 2024) exigen que los sistemas de decisión automatizada sean explicables y auditables.

La presente tesis aborda este problema mediante la extracción de reglas interpretables a partir de un modelo CatBoost entrenado sobre datos reales de préstamos personales. La metodología central es RuleCOSI+ (Obregón & Jung, 2023), un algoritmo que transita por tres etapas —extracción, combinación y simplificación— para obtener un conjunto mínimo de reglas proposicionales que aproxima fielmente el comportamiento del conjunto de árboles original. El resultado principal de este trabajo es un conjunto de cinco reglas crisp que retiene el 98,9% del F1-score del modelo CatBoost de referencia, con una Reducción de Reglas (REDU) de 0,9849.

A diferencia del enfoque previo desarrollado por Jaramillo et al. (2024) que construyó un Sistema de Inferencia Difusa de Mamdani completo a partir de 717 reglas extraídas de 25 árboles CatBoost, este trabajo prioriza la extracción de reglas crisp como entregable principal. La traducción de dichas reglas a términos lingüísticos se presenta de forma conceptual y cualitativa, con el objetivo de ilustrar cómo podría cerrarse el ciclo hacia un Sistema de Inferencia Difusa (FIS, del inglés *Fuzzy Inference System*) sin incurrir en pérdida de rendimiento en el trabajo.

Un aporte metodológico adicional de este trabajo es la identificación y corrección de una fuga de información (*data leakage*) presente en el dataset utilizado por Jaramillo et al. (2024). La variable *recoveries*, cuya naturaleza post-hoc se describe en detalle en la Sección 3, introduce información del futuro en el entrenamiento. Este trabajo elimina *recoveries* antes de cualquier entrenamiento, garantizando que el modelo aprende únicamente de variables disponibles en el momento de la decisión crediticia. La comparación entre ambos escenarios cuantifica el componente espurio introducido por la variable post-hoc; los valores se presentan y discuten en la Sección 5.

El documento está organizado de la siguiente manera: la Sección 2 presenta el marco teórico; la Sección 3 describe el dataset y el preprocesamiento; la Sección 4 detalla la metodología y la implementación; la Sección 5 reporta y discute los resultados; la Sección 6 recoge las conclusiones; y la Sección 7 lista las referencias bibliográficas.

D. F. Serrano Enríquez es estudiante de Maestría en Ciencia de Datos, Universidad San Francisco de Quito USFQ, Quito, Ecuador. Director: Edison Loza, Ph.D. Director del Programa: Felipe Grijalva, Ph.D.

II. MARCO TEÓRICO

A. Scoring Crediticio y Aprendizaje Automático

El scoring crediticio consiste en asignar una puntuación o clasificación a cada solicitante de crédito que refleje la probabilidad de incumplimiento (Thomas et al., 2017; Hand & Henley, 1997). Los modelos clásicos basados en regresión logística dominaron esta tarea durante décadas, pero su capacidad de capturar relaciones no lineales entre variables es limitada (Baesens et al., 2003). El aprendizaje automático —y en particular los métodos de ensemble— ha demostrado mejoras significativas en métricas de discriminación como el AUC-ROC y el F1-score en datasets reales de scoring (Lessmann et al., 2015; Gunnarsson et al., 2021).

Entre los algoritmos de ensemble, los árboles potenciados por gradiente han demostrado resultados consistentemente superiores en tablas de datos tabulares. CatBoost, desarrollado por Yandex (Prokhorenkova et al., 2018; Dorogush et al., 2018), incorpora un manejo nativo de variables categóricas mediante *target encoding* ordenado y emplea árboles oblivious (simétricos), en los que todos los nodos de un mismo nivel usan la misma condición de división. Esta característica hace que sus árboles sean equivalentes a tablas de búsqueda, lo que facilita la posterior extracción de reglas.

B. Árboles Oblivious y Reglas Crisp

Un árbol oblivious de profundidad d genera exactamente 2^d hojas, cada una definida por d condiciones binarias (mayor/menor que un umbral) (Kohavi & Li, 1995; Prokhorenkova et al., 2018). Con 17 árboles y profundidad 5, el CatBoost de esta tesis produce teóricamente $17 \times 32 = 544$ reglas. Sin embargo, no todas las hojas tienen cobertura positiva en el conjunto de entrenamiento: tras filtrar por cobertura > 0 , el conjunto de reglas activas se reduce a 332, que constituyen la línea base para la reducción mediante RuleCOSI+.

Cada hoja de un árbol oblivious puede expresarse como una regla crisp: una proposición de la forma “SI condición₁ Y ... Y condición _{d} ENTONCES clase”, donde cada condición es un predicado nítido sobre una variable (e.g., $fico_range_low > 647,5$). A diferencia de las reglas difusas, una regla crisp se satisface o no de forma binaria: no admite grados intermedios de pertenencia. No obstante, el conjunto de reglas crisp derivado de un ensemble completo es demasiado numeroso para ser interpretado por un analista humano; por ello, en este trabajo se emplea RuleCOSI+ (descrito en la siguiente sección) para combinar y reducir dicho conjunto a un tamaño auditable.

C. RuleCOSI+

RuleCOSI+ (Obregón & Jung, 2023) es un algoritmo de extracción de reglas interpretables a partir de conjuntos de árboles. Su premisa central es que un ensemble de árboles —preciso pero opaco— puede aproximarse mediante un conjunto compacto de reglas proposicionales que conserve

la mayor parte de su capacidad predictiva. Para lograrlo, el algoritmo combina y simplifica de manera iterativa las reglas derivadas de cada árbol, evaluando en cada paso la confianza y la cobertura del conjunto resultante y descartando las reglas redundantes o poco informativas. Constituye una extensión de RuleCOSI (Obregón et al., 2019), diseñada para operar con los principales algoritmos de gradient boosting (XGBoost, LightGBM y CatBoost, entre otros). Su pipeline se divide en tres etapas:

- 1) **Extracción:** cada árbol del ensemble se convierte directamente en un conjunto de reglas if-then-else. Las condiciones son crisp (sin ninguna fuzzificación en esta etapa).
- 2) **Combinación:** las reglas de todos los árboles se combinan mediante el algoritmo C4.5 modificado, priorizando aquellas con mayor confianza (*conf*) y cobertura (*cov*).
- 3) **Simplificación:** reglas con confianza menor al umbral α o cobertura menor al umbral β son podadas. El parámetro c controla la intensidad de la poda C4.5.

El resultado es un conjunto de reglas compacto que puede ser evaluado de forma determinista: dado un ejemplo nuevo, las reglas se evalúan en orden y se aplica la primera que se cumple (o la regla por defecto si ninguna aplica). La métrica REDU cuantifica la reducción lograda:

$$REDU = 1 - \frac{n_{\text{finales}}}{n_{\text{baseline}}} \quad (1)$$

Un REDU cercano a 1 indica una reducción drástica en la complejidad del modelo, lo que favorece la auditabilidad y la explicabilidad.

D. Sistemas de Inferencia Difusa

Un Sistema de Inferencia Difusa de Mamdani (Mamdani & Assilian, 1975) opera en cuatro etapas: (1) fuzzificación de las entradas mediante funciones de membresía que mapean valores crisp a grados de pertenencia en conjuntos difusos; (2) evaluación de reglas difusas con operadores t-norma (típicamente mínimo); (3) agregación de las salidas difusas; y (4) defuzzificación para obtener un valor crisp de salida. Aunque los FIS ofrecen alta interpretabilidad y alinean las reglas con el lenguaje humano (e.g., “FICO es BUENO”), su construcción manual a partir de reglas crisp de alta dimensionalidad puede generar una pérdida significativa de rendimiento si los umbrales de membresía no se optimizan cuidadosamente (Guillaume, 2001).

Un antecedente directo de esta línea de investigación es el trabajo de Jaramillo et al. (2024), que construyó un FIS de Mamdani completo para scoring crediticio sobre el dataset de LendingClub: a partir de un ensemble CatBoost de 25 árboles se extrajeron 717 reglas crisp, que luego fueron fuzzificadas para alimentar el motor de inferencia. Si bien el sistema resultante alcanzó una alta interpretabilidad lingüística, su rendimiento predictivo se degradó de forma

sustancial respecto del modelo base. Este trabajo toma dicho antecedente como punto de comparación directo; los contrastes metodológicos y de resultados se discuten en detalle en la Sección 5.

III. DESCRIPCIÓN DEL DATASET Y PREPROCESAMIENTO

A. Fuente de Datos

El dataset utilizado proviene de LendingClub (LendingClub Corporation, 2020), una plataforma estadounidense de préstamos entre pares (*peer-to-peer lending*). El conjunto original contiene 2.260.701 registros y más de 150 variables que describen las características del solicitante, el préstamo aprobado y el estado de pago. La variable objetivo es *bad_good*, codificada como 1 si el préstamo resultó en incumplimiento (*Charged Off*, *Default*, *Late*) y 0 en caso contrario.

El balance de clases es marcadamente asimétrico: aproximadamente el 80,5 % de los registros corresponden a la clase 0 (buenos pagadores) y el 19,5 % a la clase 1 (morosos). Esta distribución es representativa del entorno real de crédito, donde los incumplimientos son una minoría.

B. Preprocesamiento

El preprocesamiento sigue una cadena de pasos sucesivos aplicada al DataFrame completo antes de cualquier partición.

Cabe destacar que el trabajo de Jaramillo et al. (2024) no identificó este problema: al incluir *recoveries* en el entrenamiento, su CatBoost asignó alta importancia a esta variable y generó reglas como “IF *recoveries* > 0.005 THEN class = 1” con confianza de 1,0. Reglas de este tipo son operacionalmente inútiles, pues en el momento de evaluar una solicitud de crédito real *recoveries* todavía vale cero para todos los solicitantes.

El efecto de esta corrección se evalúa cuantitativamente en la Sección 5, mediante la comparación entre el Escenario A (con *recoveries*, que replica el entorno de Jaramillo et al.) y el Escenario B (sin *recoveries*, metodología limpia de este trabajo).

C. Partición Anti-Leakage

Para evitar cualquier contaminación entre las particiones, el dataset limpio se divide de la siguiente forma:

- **X_{train} (70 %) / X_{test} (30 %):** partición primaria. X_{test} (559.054 muestras) queda reservado únicamente para la evaluación final. No participa en ningún paso de entrenamiento ni de selección de hiperparámetros.
- **X_{train_base} (70 % de X_{train}) / X_{train_cosi} (30 % de X_{train}):** X_{train_base} (913.122 muestras) entrena los modelos de ensemble. X_{train_cosi} (391.338 muestras) es un conjunto virgen nunca visto por el modelo base que RuleCOSI+ utiliza para extraer las reglas interpretables, evitando que el algoritmo memorice ejemplos ya aprendidos.

Table I
COMPARACIÓN DE LOS MODELOS DE ENSEMBLE CANDIDATOS.

Modelo	Train F1	Val F1	Umbral
Random Forest	0,8758	—	0,40
CatBoost	—	0,7740	0,40
LightGBM	0,8899	0,8880	—

IV. METODOLOGÍA E IMPLEMENTACIÓN

A. Selección del Modelo Base

Se entrenaron tres modelos de ensemble sobre X_{train_base} : Random Forest (200 estimadores, profundidad 5), CatBoost (200 iteraciones máximas, profundidad 5, *learning_rate*=1 con *early stopping*) y LightGBM (200 estimadores, profundidad 5). La selección se realizó por comparación del F1-score en el conjunto de validación interna de cada modelo.

Los resultados de la comparación fueron los siguientes:

Nota. Las celdas marcadas con “—” corresponden a métricas no registradas para ese modelo durante la experimentación; en el caso de CatBoost, el entrenamiento con *early stopping* reporta el F1-score sobre la validación interna en lugar del F1 de entrenamiento.

CatBoost fue seleccionado como modelo base por su compatibilidad nativa con RuleCOSI+, que explota la estructura de árboles oblivious para una extracción eficiente de reglas. El *early stopping* terminó el entrenamiento de CatBoost en 17 iteraciones, produciendo un modelo con 17 árboles de profundidad 5. El Val F1 corresponde al F1-score evaluado sobre el 30 % de validación interna utilizado por el propio algoritmo de *early stopping*.

B. Diseño del Grid de Hiperparámetros

RuleCOSI+ expone tres hiperparámetros principales que controlan el nivel de compresión y la calidad de las reglas extraídas: α (*conf_threshold*), β (*cov_threshold*) y c (intensidad de poda C4.5). Se diseñó un grid de búsqueda con 24 combinaciones:

$$\begin{aligned} \alpha &\in \{0.50; 0.95\} \times \\ \beta &\in \{0.00; 0.01; 0.10\} \times \\ c &\in \{0.01; 0.05; 0.10; 0.25\} \end{aligned} \quad (2)$$

Para cada combinación se entrena RuleCOSI+ sobre X_{train_cosi} usando el CatBoost entrenado como modelo base, y se evalúa el F1-score sobre X_{test} . Este procedimiento se aplica de forma idéntica en los dos escenarios definidos.

C. Escenarios de Evaluación

Se definen dos escenarios con el fin de cuantificar el impacto del *data leakage*:

Escenario A (referencia): el dataset incluye *recoveries* durante todo el pipeline. CatBoost se entrena con esta

variable presente. Replica, en términos generales, el entorno del trabajo de Jaramillo et al. (2024). Los resultados de este escenario ilustran cómo el leakage distorsiona la extracción de reglas.

Escenario B (definitivo): *recoveries* se elimina antes de cualquier entrenamiento. CatBoost se reentrena sin esta variable. Es el escenario metodológicamente correcto y el que se adopta como contribución principal de este trabajo.

D. Selección de la Configuración Óptima: Frontera de Pareto

Existe una tensión intrínseca entre la compresión del modelo (pocas reglas, REDU alto) y el rendimiento predictivo (F1 alto): reducir demasiado el número de reglas implica perder capacidad de discriminación. Para resolver esta tensión de forma objetiva, se construye la frontera de Pareto en el espacio (n_reglas , $F1_test$) (Deb, 2001; Miettinen, 1999).

Un punto es Pareto-óptimo si no existe otra configuración que lo domine simultáneamente en ambas dimensiones (menos reglas y mayor F1). Una vez identificados los puntos Pareto-óptimos, se selecciona el punto situado inmediatamente por encima del codo de la curva: el codo es el punto donde la ganancia marginal de F1 cae más abruptamente al aumentar el número de reglas. Este criterio favorece el equilibrio entre compresión e interpretabilidad, descartando el tramo donde añadir reglas adicionales aporta rendimiento despreciable.

E. Traducción Conceptual a Términos Lingüísticos

Como último paso metodológico se define un procedimiento para traducir las reglas crisp resultantes a términos lingüísticos, con el fin de ilustrar cómo podrían integrarse en un FIS de Mamdani. El procedimiento consta de tres pasos: (1) identificar las variables que aparecen en las condiciones de las reglas seleccionadas; (2) asignar a cada umbral numérico una etiqueta lingüística interpretable (e.g., ALTO, MODERADO, BAJO), coherente con el dominio crediticio; y (3) reexpresar cada regla como una proposición SI-ENTONCES en lenguaje natural. Las reglas finalmente seleccionadas y su traducción lingüística se presentan en la Sección 5.

Esta traducción es conceptual y no constituye un FIS implementado. Su objetivo es mostrar que el resultado de RuleCOSI+ es directamente compatible con la semántica de los sistemas difusos.

F. Implementación

El código de la solución se organiza en un único script principal (`main.py`) que implementa el pipeline completo: carga de datos, preprocesamiento, eliminación de *recoveries*, partición anti-leakage, entrenamiento de tres modelos base, selección de CatBoost, evaluación sobre X_test , y entrenamiento e inferencia de RuleCOSI+ con la configuración Pareto-óptima. El notebook `cosi_experimental_grid_v3.ipynb`

Table II
RESULTADOS REPRESENTATIVOS DEL GRID DE BÚSQUEDA EN EL ESCENARIO A (CON *RECOVERIES*).

α	β	$n_reg.$	F1	% CB	REDU
0,50	0,00	30	0,8835	99,7 %	0,9900
0,50	0,01	4	0,8810	99,4 %	0,9987
0,50	0,10	3	0,8691	98,0 %	0,9990
0,95	cualq.	0	0,0000	0,0 %	1,0000

Table III
RENDIMIENTO DEL MODELO BASE CATBOOST EN EL ESCENARIO B (SIN *RECOVERIES*).

Métrica	Valor
F1-score (validación interna)	0,7740
Umbral óptimo	0,40
Número de árboles (early stopping)	17
Profundidad	5
Reglas teóricas (17×2^5)	544
Reglas activas (cobertura > 0)	332

implementa el grid de búsqueda de 24 configuraciones y genera la frontera de Pareto en los dos escenarios.

V. RESULTADOS Y DISCUSIÓN

A. Escenario A: Grid de Búsqueda con *recoveries*

El Escenario A replica el entorno del trabajo de Jaramillo et al. al incluir *recoveries* en el dataset. La Tabla II resume los resultados representativos del grid para los valores de α y β más informativos (c varía pero no produce diferencias significativas en n_reglas para este escenario).

El hallazgo más revelador del Escenario A es que ninguna configuración con $\alpha = 0,95$ produce reglas activas. Esto se explica porque la única condición con confianza $\geq 0,95$ en el CatBoost entrenado con *recoveries* es “IF *recoveries* > 0,005 THEN class = 1” (confianza = 1,0, cobertura = 0,143). Al elevar el umbral de confianza por encima de este valor, todas las reglas que no involucran *recoveries* son descartadas. Cuando β filtra también esa regla (por ser post-hoc), no queda ninguna regla válida. Este comportamiento confirma que *recoveries* domina la estructura del modelo de Jaramillo et al. de forma artificial.

B. Escenario B: Rendimiento del Modelo Base y Grid sin *recoveries*

El CatBoost entrenado en Escenario B (sin *recoveries*, sobre X_train_base con 913.122 muestras) alcanzó los indicadores que resume la Tabla III.

El *early stopping* terminó el entrenamiento en 17 iteraciones con $learning_rate = 1$ sobre una validación interna del 30 %. El modelo resultante tiene 544 hojas teóricas (17×2^5), de las cuales 332 tienen al menos un ejemplo de cobertura en X_train_cosi . Este es el conjunto de reglas baseline sobre el que se calcula REDU. Las Figuras 1 y 2 ilustran la magnitud de la reducción alcanzada frente a este baseline.

RuleCOSI+: Reduccion de reglas (sin recoveries — CatBoost limpio)




Figure 1. Reducción de reglas: CatBoost baseline (332 reglas) VS RuleCOSI+ con la configuración seleccionada (5 reglas).




Figure 2. Número de reglas por configuración del grid; verde = cumple umbral $F1 \geq 85\%$ del CatBoost.

En el Escenario B, CatBoost se reentrena eliminando *recoveries* antes de cualquier entrenamiento. El *early stopping* converge en 17 iteraciones, alcanzando un F1-score de validación de 0,7740 y un umbral óptimo de 0,40. El descenso de F1 con respecto al CatBoost de Jaramillo et al. (0,7740 vs. 0,8887) cuantifica el componente espurio que *recoveries* aportaba al proceso de aprendizaje: sin ella, el modelo trabaja exclusivamente con variables disponibles en el momento de la decisión crediticia. La Tabla IV presenta los resultados representativos del grid en este escenario.

La diferencia crítica respecto al Escenario A aparece en la fila de $\alpha = 0,95$: en el modelo limpio, el umbral de alta confianza extrae como máximo una regla, con un F1 de

Table IV
RESULTADOS REPRESENTATIVOS DEL GRID DE BÚSQUEDA EN EL ESCENARIO B (SIN *RECOVERIES*).

α	β	c	$n_reg.$	F1	REDU
0,50	0,10	cualq.	2	0,7591	0,9940
0,50	0,01	0,10	5	0,7652	0,9849
0,50	0,00	0,10	23	0,7671	0,9307
0,95	cualq.	cualq.	0–1	<0,2500	$\geq 0,9970$




Figure 3. Heatmap de métricas del grid de 24 configuraciones (Escenario B): número de reglas (izq.), F1-score en test (centro) y condiciones promedio por regla (der.), para cada combinación de α , β y c .




Figure 4. Frontera de Pareto en el espacio (n_reglas , $F1_test$). Los rombos rojos son los tres puntos Pareto-óptimos; los círculos azules son configuraciones no dominantes. P1 es el codo de la curva; P2 (5 reglas, $F1=0,7652$) es el punto seleccionado.

apenas 0,2486 (32,1 % del CatBoost base), muy por debajo del umbral mínimo aceptable del 85 %. Esto indica que el modelo de 17 árboles entrenado sin *recoveries* no desarrolla condiciones con confianza $\geq 0,95$ que sean suficientemente informativas para cubrir el espectro completo de clases, en contraposición al Escenario A donde sí existía una — la condición sobre *recoveries* — que precisamente era la única razón de ese alto valor de confianza. La configuración definitiva de este trabajo es $\alpha = 0,50$, $\beta = 0,01$, $c = 0,10$, que produce 5 reglas basadas íntegramente en variables crediticias legítimas. La Figura 3 presenta el heatmap de métricas para las 24 configuraciones del grid.

C. Frontera de Pareto y Configuración Seleccionada

A partir de los resultados del Escenario B se identifican tres puntos Pareto-óptimos en el espacio (n_reglas , $F1_test$), que se detallan en la Tabla V.

Table V
PUNTOS PARETO-ÓPTIMOS EN EL ESPACIO (n_REGLAS , $F1_TEST$).

Punto	$n_reg.$	F1	REDU	$F1 \times REDU$	α	β	c
P1 (codo)	2	0,7591	0,9940	0,7546	0,50	0,10	cualq.
P2 ★	5	0,7652	0,9849	0,7536	0,50	0,01	0,10
P3	23	0,7671	0,9307	0,7140	0,50	0,00	0,10

Como se aprecia en la Figura 4, el salto de P1 a P2 —de 2 a 5 reglas— recupera 0,0061 puntos de F1 a cambio de solo 3 reglas adicionales. El salto siguiente, de P2 a P3 —de 5 a 23 reglas— apenas aporta 0,0019 puntos de F1 adicionales a un costo de 18 reglas más: la ganancia marginal cae un 95 %. P1 es el codo natural de la curva; P2 es el punto inmediatamente superior al codo, donde todavía se obtiene rendimiento relevante por cada regla agregada.

La configuración seleccionada es P2: $\alpha = 0,50$, $\beta = 0,01$, $c = 0,10$, que produce 5 reglas con $F1 = 0,7652$ y $REDU = 0,9849$. Esta configuración retiene el 98,9 % del rendimiento del CatBoost original comprimiendo el modelo de 332 a 5 reglas activas. Nótese que si se aplicara el criterio $\max(F1 \times REDU)$, se elegiría P1 ($0,7546 > 0,7536$); la elección de P2 refleja una decisión deliberada de priorizar el equilibrio entre compresión e interpretabilidad sobre la optimización puramente matemática de ese producto.

La configuración seleccionada produce cinco reglas crisp; el número no se fija a priori, sino que emerge de la poda de RuleCOSI+ con $\alpha = 0,50$, $\beta = 0,01$ y $c = 0,10$ sobre las 332 reglas activas del CatBoost base. Las condiciones de estas cinco reglas involucran únicamente cuatro variables —las que sobreviven a la simplificación—: *last_fico_range_high* (límite superior del último rango FICO reportado), *fico_range_low* (límite inferior del rango FICO actual), *loan_amnt* (monto del préstamo) y *debt_settlement_flag* (indicador binario de acuerdo de liquidación de deuda). Aplicando el procedimiento de traducción descrito en la Sección 4.5, los umbrales numéricos se etiquetan lingüísticamente así:

- *last_fico_range_high* > 681,5 → “FICO RECIENTE es ALTO” (historial crediticio sólido).
- *last_fico_range_high* > 596,5 → “FICO RECIENTE es ACEPTABLE” (historial básicamente positivo).
- *last_fico_range_high* ≤ 626,5 → “FICO RECIENTE es BAJO” (historial crediticio deteriorado).
- *fico_range_low* > 647,5 → “FICO ACTUAL es BUENO” (rango de crédito vigente en buen estado).
- *loan_amnt* > 8.862,5 → “MONTO es ALTO”.
- *loan_amnt* ≤ 14.812,5 → “MONTO es MODERADO”.
- *debt_settlement_flag* ≤ 0,5 → “SIN acuerdo de liquidación” (el prestatario no ha formalizado ningún acuerdo de reestructuración de deuda).

Con estas etiquetas, las cinco reglas finales —y la regla por defecto— se expresan de la siguiente manera:

- **R0:** SI FICO ACTUAL es BUENO Y FICO RE-

Table VI
COMPARACIÓN DE ENFOQUES: ESTE TRABAJO FRENTE A JARAMILLO ET AL. (2024).

Enfoque		$n_reg.$	F1	<i>recoveries</i>
CatBoost (leakage)	Jaramillo	—	0,8887	Sí
FIS	Mamdani	717	0,4963	Sí
Jaramillo				
CatBoost (Esc. B)	limpio	—	0,7740	No
RuleCOSI+ P2 (este trabajo)		5	0,7652	No

CIENTE es ALTO Y SIN acuerdo de liquidación → buen pagador (conf = 0,99; cubre el 56,8 % de los casos).

- **R1:** SI FICO ACTUAL es BUENO Y FICO RECIENTE es BAJO Y MONTO es ALTO → impago probable (conf = 0,71; cubre el 17,4 %).
- **R2:** SI FICO ACTUAL es BUENO Y FICO RECIENTE es ACEPTABLE Y SIN acuerdo de liquidación Y MONTO es MODERADO → buen pagador (conf = 0,90; cubre el 12,5 %).
- **R3:** SI FICO ACTUAL es BUENO Y FICO RECIENTE es ACEPTABLE Y SIN acuerdo de liquidación → buen pagador (conf = 0,85; cubre el 6,7 %).
- **R4:** SI FICO ACTUAL es BUENO Y FICO RECIENTE es BAJO → impago probable (conf = 0,60; cubre el 5,9 %).
- **REGLA POR DEFECTO:** impago probable (cubre el 0,7 % restante).

D. Discusión

La Tabla VI compara los tres enfoques evaluados en este trabajo y en el de Jaramillo et al. (2024).

Los resultados revelan dos contrastes fundamentales. Primero, el FIS de Jaramillo et al. incurre en una pérdida de F1 del 44,2 % respecto a su propio CatBoost de referencia (de 0,8887 a 0,4963). Esta pérdida es atribuible a la combinación de: (a) la alta dimensionalidad del espacio de reglas (717 reglas de 25 árboles), (b) la discretización imprecisa de las variables continuas en conjuntos difusos sin optimización, y (c) el manejo del umbral de decisión en la defuzzificación. En contraste, RuleCOSI+ reduce el modelo de 332 a 5 reglas perdiendo únicamente 1,1 % de F1 (de 0,7740 a 0,7652).

Segundo, la comparación entre el CatBoost de Jaramillo et al. ($F1 = 0,8887$, con *recoveries*) y el CatBoost limpio

de este trabajo ($F1 = 0,7740$, sin *recoveries*) indica que la variable post-hoc *recoveries* inflaba artificialmente el rendimiento en 0,1147 puntos de F1. Esta diferencia no refleja capacidad predictiva genuina sino una dependencia espuria aprendida por el modelo de Jaramillo et al.: cuando *recoveries* = 0 (valor de todas las solicitudes nuevas en producción), el modelo de Jaramillo et al. pierde su principal ancla de clasificación. Las cinco reglas del Escenario B, al basarse exclusivamente en variables crediticias disponibles en el momento de la solicitud (puntaje FICO, monto del préstamo, indicador de acuerdo de liquidación), son operacionalmente válidas y desplegables en un entorno de producción real.

Los resultados de este trabajo tienen tres implicaciones prácticas relevantes. Primera, la reducción de 332 a 5 reglas ($REDU = 0,9849$) con pérdida mínima de rendimiento representa un equilibrio favorable entre interpretabilidad y precisión: cinco reglas pueden ser revisadas, validadas y comunicadas por analistas de riesgo sin herramientas especializadas, mientras que 332 reglas requieren técnicas avanzadas de explicabilidad. Segunda, la corrección del *data leakage* no solo es metodológicamente necesaria sino que también tiene implicaciones regulatorias: un modelo que utiliza *recoveries* en producción estaría tomando decisiones basadas en información que aún no existe, lo que podría constituir una violación de requisitos de equidad y transparencia en sistemas de crédito. Tercera, la comparación directa con el FIS de Jaramillo et al. muestra que la fuzzificación, aplicada sin optimización de funciones de membresía, puede degradar severamente el rendimiento. La extracción de reglas crisp mediante RuleCOSI+ ofrece una alternativa más robusta que puede complementarse con una fuzzificación cuidadosamente calibrada en trabajos futuros.

VI. CONCLUSIONES

Este trabajo abordó el problema de la interpretabilidad en modelos de scoring crediticio de alto rendimiento, con el objetivo de extraer reglas comprensibles a partir de un CatBoost entrenado sobre el dataset de LendingClub. Los resultados permiten formular las siguientes conclusiones:

1. Extracción eficiente de reglas crisp con retención de rendimiento casi completa. La configuración Pareto-óptima seleccionada ($\alpha = 0,50$, $\beta = 0,01$, $c = 0,10$) produce cinco reglas crisp con un F1-score de 0,7652 sobre el conjunto de prueba, lo que representa el 98,9% del rendimiento del CatBoost de referencia ($F1 = 0,7740$). La Reducción de Reglas es $REDU = 0,9849$: el modelo pasa de 332 reglas activas a 5, manteniendo casi toda su capacidad predictiva.

2. Corrección de una fuga de información presente en el trabajo previo de Jaramillo et al. (2024). La variable *recoveries* es post-hoc: su valor solo se conoce después de producido el incumplimiento. Al eliminarla antes de cualquier entrenamiento, el modelo aprende exclusivamente de variables disponibles en el momento de la

decisión crediticia. El Escenario A (con *recoveries*) confirma el problema: con $\alpha = 0,95$, ninguna regla se extrae porque la única condición de alta confianza involucra *recoveries* y, al filtrarla, no queda ninguna regla activa. El Escenario B (sin *recoveries*) demuestra que sin la variable espuria el modelo construye cinco reglas basadas en indicadores crediticios legítimos (FICO, monto del préstamo, historial de liquidaciones). Este hallazgo tiene relevancia directa para la aplicabilidad de los modelos en producción y para el cumplimiento de marcos regulatorios de explicabilidad.

3. Superioridad del enfoque RuleCOSI+ frente al FIS de Mamdani en la tarea evaluada. El FIS de Mamdani implementado en el trabajo de Jaramillo et al. (2024) perdió el 44,2% del F1-score del modelo base al construir 717 reglas difusas desde 25 árboles. El enfoque de este trabajo, que extrae 5 reglas crisp desde 17 árboles mediante RuleCOSI+, pierde únicamente el 1,1%. Esta diferencia sugiere que la pérdida en el trabajo de Jaramillo et al. no se debe a una limitación inherente del paradigma difuso, sino a las decisiones de diseño del FIS (número de árboles fuente, funciones de membresía sin optimización, umbral de defuzzificación). Las cinco reglas crisp obtenidas aquí son directamente traducibles a términos lingüísticos difusos, lo que hace factible construir un FIS de alta precisión como extensión futura.

4. La frontera de Pareto como herramienta objetiva de selección. La construcción explícita de la frontera de Pareto en el espacio (n_reglas , $F1_test$) permitió identificar tres configuraciones no dominadas y seleccionar P2 como el punto de mayor equilibrio mediante el criterio del codo: pasar de 2 a 5 reglas recupera 0,0061 de F1 adicional (ganancia relevante); pasar de 5 a 23 reglas solo aporta 0,0019 de F1 con 18 reglas adicionales (ganancia marginal despreciable). Este procedimiento puede aplicarse directamente a otros problemas de extracción de reglas donde se busque equilibrar compresión y rendimiento.

5. Limitaciones de la investigación. Los resultados deben interpretarse considerando varias limitaciones. Primero, el estudio se basa en un único dataset (LendingClub, mercado estadounidense), por lo que la generalización de las reglas a otras carteras o contextos regulatorios no está garantizada. Segundo, la traducción lingüística de las reglas es conceptual: no se implementó ni validó un FIS ejecutable, de modo que la viabilidad de un sistema difuso de alta precisión construido sobre estas reglas permanece como hipótesis. Tercero, la comparación con Jaramillo et al. (2024) está condicionada por diferencias de configuración entre ambos trabajos (número de árboles fuente y esquemas de partición), por lo que las brechas reportadas combinan el efecto del método y el de dichas diferencias. Finalmente, la selección de la configuración óptima mediante el criterio del codo depende del grid explorado; otros espacios de búsqueda podrían producir fronteras de Pareto distintas.

6. Trabajo futuro. Las extensiones naturales de este trabajo incluyen: (a) fuzzificación calibrada de las cinco reglas crisp mediante optimización de funciones de mem-

bresía con datos históricos, para construir un FIS de alta precisión; (b) validación del pipeline en otros datasets de crédito (e.g., German Credit, Give Me Some Credit) para evaluar la generalización; (c) incorporación de restricciones de equidad (*fairness*) en el proceso de selección de reglas; y (d) exploración de técnicas de explicabilidad post-hoc (SHAP, LIME) complementarias a las reglas crisp para usuarios no técnicos.

En síntesis, esta tesis demuestra que es posible comprimir un modelo CatBoost de 332 reglas activas a 5 reglas interpretables, retener el 98,9% del rendimiento, y hacerlo sobre datos libres de fuga de información. Las cinco reglas resultantes son auditables, comunicables a reguladores y desplegables en un entorno de producción real, lo que las convierte en una herramienta concreta para la toma de decisiones crediticias transparente y responsable.

REFERENCES

- [1] L. Obregón y A. Jung, “RuleCOSI+: Rule Extraction Algorithm for Accurate and Interpretable Classification,” *Expert Systems with Applications*, vol. 216, pp. 119–132, 2023. <https://doi.org/10.1016/j.eswa.2022.119432>
- [2] A. V. Dorogush, V. Ershov, y A. Gulin, “CatBoost: gradient boosting with categorical features support,” *arXiv:1810.11363*, 2018. <https://arxiv.org/abs/1810.11363>
- [3] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye y T.-Y. Liu, “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” en *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 3149–3157, 2017.
- [4] T. Chen y C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” en *Proc. 22nd ACM SIGKDD*, pp. 785–794, 2016. <https://doi.org/10.1145/2939672.2939785>
- [5] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. <https://doi.org/10.1023/A:1010933404324>
- [6] E. Bauer y R. Kohavi, “An Empirical Comparison of Voting Classification Algorithms: Bagging, Boosting, and Variants,” *Machine Learning*, vol. 36, no. 1–2, pp. 105–139, 1999. <https://doi.org/10.1023/A:1007515423169>
- [7] B. Jaramillo, “Extracción de Reglas Difusas desde Árboles de Decisión para Scoring Crediticio,” Tesis de Maestría, Universidad San Francisco de Quito, 2024.
- [8] L.-A. Zadeh, “Fuzzy sets,” *Information and Control*, vol. 8, no. 3, pp. 338–353, 1965. [https://doi.org/10.1016/S0019-9958\(65\)90241-X](https://doi.org/10.1016/S0019-9958(65)90241-X)
- [9] E. H. Mamdani y S. Assilian, “An experiment in linguistic synthesis with a fuzzy logic controller,” *International Journal of Man-Machine Studies*, vol. 7, no. 1, pp. 1–13, 1975. [https://doi.org/10.1016/S0020-7373\(75\)80002-2](https://doi.org/10.1016/S0020-7373(75)80002-2)
- [10] LendingClub Corporation, “LendingClub Loan Data,” Kaggle, 2020. <https://www.kaggle.com/datasets/wordsforthewise/lending-club>
- [11] Comisión Europea, “Reglamento sobre Inteligencia Artificial (AI Act),” *Diario Oficial de la Unión Europea*, 2024. <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32024R1689>
- [12] L. C. Thomas, J. N. Crook y D. B. Edelman, *Credit Scoring and Its Applications*, 2.^a ed., SIAM, 2017. <https://doi.org/10.1137/1.9781611974560>
- [13] D. J. Hand y W. E. Henley, “Statistical Classification Methods in Consumer Credit Scoring: a Review,” *Journal of the Royal Statistical Society: Series A*, vol. 160, no. 3, pp. 523–541, 1997. <https://doi.org/10.1111/j.1467-985X.1997.00078.x>
- [14] E. I. Altman, “Financial Ratios, Discriminant Analysis and the Prediction of Corporate Bankruptcy,” *The Journal of Finance*, vol. 23, no. 4, pp. 589–609, 1968. <https://doi.org/10.1111/j.1540-6261.1968.tb00843.x>
- [15] J. C. Wiginton, “A Note on the Comparison of Logit and Discriminant Models of Consumer Credit Behavior,” *Journal of Financial and Quantitative Analysis*, vol. 15, no. 3, pp. 757–770, 1980. <https://doi.org/10.2307/2330408>
- [16] S. Lessmann, B. Baesens, H.-V. Seow y L. C. Thomas, “Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research,” *European Journal of Operational Research*, vol. 247, no. 1, pp. 124–136, 2015. <https://doi.org/10.1016/j.ejor.2015.05.030>
- [17] B. Gunnarsson, S. vanden Broucke, B. Baesens, M. Óskarsdóttir y W. Lemahieu, “Deep learning for credit scoring: Do or don’t?,” *European Journal of Operational Research*, vol. 295, no. 1, pp. 292–305, 2021. <https://doi.org/10.1016/j.ejor.2021.03.006>
- [18] B. Baesens, T. Van Gestel, S. Viaene, M. Stepanova, J. Suykens y J. Vanthienen, “Benchmarking state-of-the-art classification algorithms for credit scoring,” *Journal of the Operational Research Society*, vol. 54, no. 6, pp. 627–635, 2003. <https://doi.org/10.1057/palgrave.jors.2601545>
- [19] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush y A. Gulin, “CatBoost: unbiased boosting with categorical features,” en *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 6638–6648, 2018.
- [20] R. Kohavi y C.-H. Li, “Oblivious Decision Trees, Graphs, and Top-Down Pruning,” en *Proc. 14th IJCAI*, pp. 1071–1077, 1995.
- [21] C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, vol. 1, no. 5, pp. 206–215, 2019. <https://doi.org/10.1038/s42256-019-0048-x>
- [22] S. Guillaume, “Designing fuzzy inference systems from data: An interpretability-oriented review,” *IEEE Transactions on Fuzzy Systems*, vol. 9, no. 3, pp. 426–443, 2001. <https://doi.org/10.1109/91.928739>
- [23] K. Deb, *Multi-Objective Optimization Using Evolutionary Algorithms*, Wiley, 2001.
- [24] K. Miettinen, *Nonlinear Multiobjective Optimization*, Kluwer Academic Publishers, 1999.
- [25] Comité de Supervisión Bancaria de Basilea, “Basel III: Finalising post-crisis reforms,” Banco de Pagos Internacionales, 2017. <https://www.bis.org/bcbs/publ/d424.htm>
- [26] J. Obregón, A. Kim y J.-Y. Jung, “RuleCOSI: Combination and simplification of production rules from boosted decision trees for imbalanced classification,” *Expert Systems with Applications*, vol. 126, pp. 64–82, 2019. <https://doi.org/10.1016/j.eswa.2019.02.012>