

UNIVERSIDAD SAN FRANCISCO DE QUITO

Colegio de Ciencias e Ingeniería

**Extracción de Reglas Interpretables
mediante RuleCOSI+ y Análisis de Frontera de Pareto**

Danilo Serrano Enríquez

Tesis de Maestría en Inteligencia de Negocios y Ciencia de Datos

Quito, Ecuador - 2024

1. Introducción

El scoring crediticio es uno de los procesos más críticos en la industria financiera (Thomas et al., 2017). Determinar con precisión si un solicitante pagará o no su obligación tiene implicaciones directas sobre la rentabilidad de las instituciones y el bienestar económico de sus clientes (Hand & Henley, 1997). Durante décadas, este proceso se apoyó en modelos estadísticos clásicos (—regresión logística, análisis discriminante—) que ofrecen resultados interpretables interpretables, pero limitan la capacidad predictiva (Altman, 1968; Wiginton, 1980). En años recientes, el aprendizaje automático ha desplazado progresivamente esos métodos, alcanzando niveles de precisión que difícilmente se logran con modelos tradicionales (e.g., Lessmann et al., 2015; Gunnarsson et al., 2021).

Sin embargo, el auge de los modelos de aprendizaje automático no llega sin costo. Algoritmos como los árboles de decisión potenciados por gradiente (CatBoost, XGBoost, LightGBM) (Dorogush et al., 2018; Chen & Guestrin, 2016; Ke et al., 2017) funcionan como cajas negras: sus predicciones son difíciles de auditar, comunicar a reguladores y justificar ante clientes que solicitan explicación de una decisión adversa (Rudin, 2019). Este problema es especialmente relevante en el contexto regulatorio actual, donde marcos como Basilea III (Comité de Supervisión Bancaria de Basilea, 2017) y el Reglamento de Inteligencia Artificial de la Unión Europea (Comisión Europea, 2024) exigen que los sistemas de decisión automatizada sean explicables y auditables.

Para abordar las limitaciones de los algoritmos mencionados, el presente trabajo de titulación ~~La presente tesis~~ aborda este problema mediante la extracción de reglas interpretables a partir de un modelo CatBoost entrenado sobre datos reales de préstamos personales. La metodología central ~~utilizadas~~ es RuleCOSI+ (Obregón & Jung, 2023), un algoritmo que transita por tres etapas (—extracción, combinación y simplificación—) para obtener un conjunto mínimo de reglas proposicionales que aproxima fielmente el comportamiento del conjunto de árboles original. El resultado principal de este trabajo es un conjunto de cinco reglas crisp que retiene el 98,9 % del F1-score del modelo CatBoost de referencia, con una Reducción de Reglas (REDU) de 0,9849.

A diferencia del enfoque previo desarrollado por Jaramillo et al. (2024), ~~—en adelante denominado trabajo de Byron—~~, que construyó un Sistema de Inferencia Difusa de Mamdani completo a partir de 717 reglas extraídas de 25 árboles CatBoost, este trabajo prioriza la extracción de reglas crisp como entregable principal. La traducción de dichas reglas a términos lingüísticos se presenta de forma conceptual y cualitativa, con el objetivo de ilustrar cómo podría cerrarse el ciclo hacia un Sistema de Inferencia Difusa (FIS, del inglés Fuzzy Inference System) ~~sin incurrir en la pérdida de rendimiento observada y corrigiendo un problema de fuga de información identificado en el trabajo de Byron~~ ~~ibid.~~.

Un aporte metodológico adicional de este trabajo ~~reside en es~~ la identificación y corrección de una fuga de información (data leakage) presente en el dataset utilizado por Jaramillo et al. (2024). La variable *recoveries*, cuya naturaleza post-hoc se describe en detalle en la Sección 3, introduce información del futuro en el entrenamiento. Este trabajo elimina *recoveries* antes de cualquier entrenamiento, garantizando que el modelo aprende únicamente de variables disponibles en el momento de la decisión crediticia. La comparación entre ambos escenarios cuantifica el componente espurio introducido por la variable post-hoc; los valores se presentan y discuten en la Sección 5.

El documento está organizado de la siguiente manera: la Sección 2 presenta el marco teórico; la Sección 3 describe el dataset y el preprocesamiento; la Sección 4 detalla la metodología y la

Comentado [ELA1]: poner una referencia

Comentado [D2R1]: Referencia agregada: (Thomas et al., 2017).

Comentado [ELA3]: referencia

Comentado [D4R3]: Referencia agregada: (Hand & Henley, 1997).

Comentado [ELA5]: referencia

Comentado [D6R5]: Referencias agregadas: (Altman, 1968; Wiginton, 1980).

Comentado [ELA7]: ejemplos (e.g.)

Comentado [D8R7]: Ejemplos agregados: (e.g., Lessmann et al., 2015; Gunnarsson et al., 2021).

Comentado [ELA9]: referencia

Comentado [D10R9]: Referencias agregadas: (Dorogush et al., 2018; Chen & Guestrin, 2016; Ke et al., 2017) y (Rudin, 2019) para el problema de cajas negras.

Comentado [ELA11]: referencias a estos dos cuerpos legales

Comentado [D12R11]: Referencias agregadas a ambos cuerpos legales: Comité de Supervisión Bancaria de Basilea (2017) y Comisión Europea (2024).

Comentado [ELA13]: hasta este punto no se ha definido esta abreviación

Comentado [D14R13]: FIS ahora se define en su primera aparición en la introducción: "Sistema de Inferencia Difusa (FIS, del inglés Fuzzy Inference System)".

Comentado [ELA15]: esto lo movemos y lo ponemos en discusión.

Comentado [D16R15]: Movido: el detalle del F1 (44 %, 0,8887→0,4963) salió de la introducción y se trata en la Discusión (5.4).

Comentado [ELA17]: esto lo movemos y lo ponemos en discusión

Comentado [D18R17]: Movido: la descripción de *recoveries* salió de la introducción; ahora se desarrolla en el preprocesamiento (3.2) y su efecto se discute en 5.4.

implementación; la Sección 5 reporta y discute los resultados; la Sección 6 recoge las conclusiones; y la Sección 7 lista las referencias bibliográficas.

Con formato: Justificado, Espacio Después: 6 pto

2. Marco Teórico

2.1 Scoring Crediticio y Aprendizaje Automático

El scoring crediticio consiste en asignar una puntuación o clasificación a cada solicitante de crédito que refleje la probabilidad de incumplimiento (Thomas et al., 2017; Hand & Henley, 1997). Los modelos clásicos basados en regresión logística dominaron esta tarea durante décadas, pero su capacidad de capturar relaciones no lineales entre variables es limitada (Baesens et al., 2003). El aprendizaje automático —y en particular los métodos de ensemble— ha demostrado mejoras significativas en métricas de discriminación como el AUC-ROC y el F1-score en datasets reales de scoring (Lessmann et al., 2015; Gunnarsson et al., 2021).

Entre los algoritmos de ensemble, los árboles potenciados por gradiente han demostrado resultados consistentemente superiores en tablas de datos tabulares. CatBoost, desarrollado por Yandex (Prokhorenkova et al., 2018; Dorogush et al., 2018), incorpora un manejo nativo de variables categóricas mediante target encoding ordenado y emplea árboles oblivious (simétricos), en los que todos los nodos de un mismo nivel usan la misma condición de división. Esta característica hace que sus árboles sean equivalentes a tablas de búsqueda, lo que facilita la posterior extracción de reglas.

2.2 Árboles Oblivious y Reglas Crisp

Un árbol oblivious de profundidad d genera exactamente 2^d hojas, cada una definida por d condiciones binarias (mayor/menor que un umbral) (Kohavi & Li, 1995; Prokhorenkova et al., 2018). Con 17 árboles y profundidad 5, el CatBoost de esta tesis produce teóricamente $17 \times 32 = 544$ reglas. Sin embargo, no todas las hojas tienen cobertura positiva en el conjunto de entrenamiento: tras filtrar por cobertura > 0 , el conjunto de reglas activas se reduce a 332, que constituyen la línea base para la reducción mediante RuleCOSI+.

Cada hoja de un árbol oblivious puede expresarse como una regla crisp: una proposición de la forma "SI condición₁ Y ... Y condición_d ENTONCES clase", donde cada condición es un predicado nítido sobre una variable (e.g., `fico_range_low > 647,5`). A diferencia de las reglas difusas, una regla crisp se satisface o no de forma binaria: no admite grados intermedios de pertenencia. No obstante, el conjunto de reglas crisp derivado de un ensemble completo es demasiado numeroso para ser interpretado por un analista humano; por ello, en este trabajo se emplea RuleCOSI+ (descrito en la siguiente sección) para combinar y reducir dicho conjunto a un tamaño auditable.

2.3 RuleCOSI+

RuleCOSI+ (Obregón & Jung, 2023) es un algoritmo de extracción de reglas interpretables a partir de conjuntos de árboles. Su premisa central es que un ensemble de árboles —preciso pero opaco— puede aproximarse mediante un conjunto compacto de reglas proposicionales que conserve la mayor parte de su capacidad predictiva. Para lograrlo, el algoritmo combina y simplifica de manera iterativa las reglas derivadas de cada árbol, evaluando en cada paso la confianza y la cobertura del conjunto resultante y descartando las reglas redundantes o poco informativas. Constituye una extensión de RuleCOSI (Obregón et al., 2019), diseñada para operar con los principales algoritmos de gradient boosting (XGBoost, LightGBM y CatBoost, entre otros). Su pipeline se divide en tres etapas:

1. **Extracción:** cada árbol del ensemble se convierte directamente en un conjunto de reglas if-then-else. Las condiciones son crisp (sin ninguna fuzzificación en esta etapa).

Comentado [ELA19]: usar referencias para toda la sección 2.1, si se puede, las mismas de la introducción y una o dos adicionales

Comentado [D20R19]: Referencias agregadas en toda la sección 2.1: las mismas de la introducción más (Baesens et al., 2003).

Comentado [ELA21]: poner referencias

Comentado [D22R21]: Referencias agregadas: (Kohavi & Li, 1995; Prokhorenkova et al., 2018).

Comentado [ELA23]: no se habla de reglas crisp, no se las define formalmente.

Comentado [D24R23]: Se agregó un párrafo en 2.2 que define formalmente las reglas crisp (proposiciones SI-ENTONCES con predicados nítidos, sin grados de pertenencia).

Comentado [ELA25]: introducir en la sección anterior, nuevamente que usamos rulecosi para reducir el número de reglas

Comentado [D26R25]: El párrafo nuevo al final de 2.2 introduce que usamos RuleCOSI+ para combinar y reducir el conjunto de reglas a un tamaño auditable.

2. **Combinación:** las reglas de todos los árboles se combinan mediante el algoritmo C4.5 modificado, priorizando aquellas con mayor confianza (conf) y cobertura (cov).
3. **Simplificación:** reglas con confianza menor al umbral α o cobertura menor al umbral β son podadas. El parámetro c controla la intensidad de la poda C4.5.

El resultado es un conjunto de reglas compacto que puede ser evaluado de forma determinista: dado un ejemplo nuevo, las reglas se evalúan en orden y se aplica la primera que se cumple (o la regla por defecto si ninguna aplica). La métrica REDU cuantifica la reducción lograda:

$$REDU = 1 - (n_reglas_finales / n_reglas_baseline)$$

Un REDU cercano a 1 indica una reducción drástica en la complejidad del modelo, lo que favorece la auditabilidad y la explicabilidad.

2.4 Sistemas de Inferencia Difusa

Un ~~Sistema de Inferencia Difusa~~^{SIF} de Mamdani (Mamdani & Assilian, 1975) opera en cuatro etapas: (1) fuzzificación de las entradas mediante funciones de membresía que mapean valores crisp a grados de pertenencia en conjuntos difusos; (2) evaluación de reglas difusas con operadores t-norma (típicamente mínimo); (3) agregación de las salidas difusas; y (4) defuzzificación para obtener un valor crisp de salida. Aunque los FIS ofrecen alta interpretabilidad y alinean las reglas con el lenguaje humano (e.g., "FICO es BUENO¹"), su construcción manual a partir de reglas crisp de alta dimensionalidad puede generar una pérdida significativa de rendimiento si los umbrales de membresía no se optimizan cuidadosamente (Guillaume, 2001).

En este trabajo, la fuzzificación se aborda de forma conceptual: las reglas crisp finalmente seleccionadas se traducen a términos lingüísticos para ilustrar cómo podrían integrarse en un FIS, sin implementar el motor de inferencia completo.

Un antecedente directo de esta línea de investigación es el trabajo de Jaramillo et al. (2024), que construyó un FIS de Mamdani completo para scoring crediticio sobre el dataset de LendingClub: a partir de un ensemble CatBoost de 25 árboles se extrajeron 717 reglas crisp, que luego fueron fuzzificadas para alimentar el motor de inferencia. Si bien el sistema resultante alcanzó una alta interpretabilidad lingüística, su rendimiento predictivo se degradó de forma sustancial respecto del modelo base. Este trabajo toma dicho antecedente como punto de comparación directo; los contrastes metodológicos y de resultados se discuten en detalle en la Sección 5.

Comentado [ELA27]: aumentar la redacción

Comentado [D28R27]: Redacción ampliada: se explica la premisa del algoritmo, su funcionamiento iterativo y su relación con RuleCOSI (Obregón et al., 2019), referencia [26] nueva.

Comentado [ELA29]: de o según? Mamdani es un autor? si es así, poner la referencia

Comentado [D30R29]: Mamdani es autor; se agregó la referencia (Mamdani & Assilian, 1975).

Comentado [ELA31]: definir qué es FICO?

Comentado [D32R31]: Se agregó una nota al pie definiendo FICO (puntaje crediticio de Fair Isaac Corporation) en su primera mención.

Comentado [ELA33]: referencia

Comentado [D34R33]: Referencia agregada: (Guillaume, 2001).

Comentado [ELA35]: en este punto del trabajo aún no sabemos que son cinco reglas

Comentado [D36R35]: Corregido: se quitó el número; ahora dice "las reglas crisp finalmente seleccionadas".

Comentado [ELA37]: incluir un párrafo que hable del trabajo de Jaramillo para luego poder discutir contra esto.

Comentado [D38R37]: Se agregó al final de 2.4 un párrafo que describe el trabajo de Jaramillo et al. (2024) como antecedente directo, sin adelantar cifras de resultados.

¹ FICO es el puntaje crediticio desarrollado por Fair Isaac Corporation, de uso estándar en Estados Unidos; resume el historial crediticio del solicitante en un valor típicamente entre 300 y 850.

3. Descripción del Dataset y Preprocesamiento

3.1 Fuente de Datos

El dataset utilizado proviene de **LendingClub** (LendingClub Corporation, 2020)², una plataforma estadounidense de préstamos entre pares (peer-to-peer lending). El conjunto original contiene 2.260.701 registros y más de 150 variables que describen las características del solicitante, el préstamo aprobado y el estado de pago. La variable objetivo es `bad_good`, codificada como 1 si el préstamo resultó en incumplimiento (Charged Off, Default, Late) y 0 en caso contrario.

El balance de clases es marcadamente asimétrico: aproximadamente el 80,5 % de los registros corresponden a la clase 0 (buenos pagadores) y el 19,5 % a la clase 1 (morosos). Esta distribución es representativa del entorno real de crédito, donde los incumplimientos son una minoría.

3.2 Preprocesamiento

El preprocesamiento sigue una cadena de pasos sucesivos aplicada al DataFrame completo antes de cualquier partición:

Cabe destacar que el trabajo de Jaramillo et al. (2024) no identificó este problema: al incluir `recoveries` en el entrenamiento, su CatBoost asignó alta importancia a esta variable y generó reglas como "IF `recoveries` > 0.005 THEN `class` = 1" con confianza de 1,0. Reglas de este tipo son operacionalmente inútiles, pues en el momento de evaluar una solicitud de crédito real `recoveries` todavía vale cero para todos los solicitantes.

El efecto de esta corrección se evalúa cuantitativamente en la Sección 5, mediante la comparación entre el Escenario A (con `recoveries`, que replica el entorno de Jaramillo et al.) y el Escenario B (sin `recoveries`, metodología limpia de este trabajo).

3.3 Partición Anti-Leakage

Para evitar cualquier contaminación entre las particiones, el dataset limpio se divide de la siguiente forma:

1. **X_train (70 %) / X_test (30 %):** partición primaria. `X_test` (559.054 muestras) queda reservado únicamente para la evaluación final. No participa en ningún paso de entrenamiento ni de selección de hiperparámetros.
2. **X_train_base (70 % de X_train) / X_train_cosi (30 % de X_train):** `X_train_base` (913.122 muestras) entrena los modelos de ensemble. `X_train_cosi` (391.338 muestras) es un conjunto virgen (—nunca visto por el modelo base—) que RuleCOSI+ utiliza para extraer las reglas interpretables, evitando que el algoritmo memorice ejemplos ya aprendidos.

Comentado [ELA39]: poner una referencia o nota a pie de página para que se pueda consultar los datos.

Comentado [D40R39]: Se agregó la cita (LendingClub Corporation, 2020) y una nota al pie con la URL de los datos.

² Los datos pueden consultarse públicamente en: <https://www.kaggle.com/datasets/wordsforthewise/lending-club>

4. Metodología e Implementación

4.1 Selección del Modelo Base

Se entrenaron tres modelos de ensemble sobre `X_train_base`: Random Forest (200 estimadores, profundidad 5), CatBoost (200 iteraciones máximas, profundidad 5, `learning_rate=1` con early stopping) y LightGBM (200 estimadores, profundidad 5). La selección se realizó por comparación del F1-score en el conjunto de validación interna de cada modelo (Tabla 1).

Los resultados de la comparación fueron los siguientes:

Tabla 1. Comparación de los modelos de ensemble candidatos: F1-score en entrenamiento y validación interna, y umbral de clasificación óptimo.

Modelo	Train F1	Val F1	Umbral óptimo
Random Forest	0,8758	—	0,40
CatBoost	—	0,7740	0,40
LightGBM	0,8899	0,8880	—

Nota. Las celdas marcadas con “—” corresponden a métricas no registradas para ese modelo durante la experimentación; en el caso de CatBoost, el entrenamiento con early stopping reporta el F1-score sobre la validación interna en lugar del F1 de entrenamiento.

CatBoost fue seleccionado como modelo base por su compatibilidad nativa con RuleCOSI+, que explota la estructura de árboles oblivious para una extracción eficiente de reglas. El early stopping terminó el entrenamiento de CatBoost en 17 iteraciones, produciendo un modelo con 17 árboles de profundidad 5. El Val F1 corresponde al F1-score evaluado sobre el 30 % de validación interna utilizado por el propio algoritmo de early stopping.

4.2 Diseño del Grid de Hiperparámetros

RuleCOSI+ expone tres hiperparámetros principales que controlan el nivel de compresión y la calidad de las reglas extraídas: α (`conf_threshold`), β (`cov_threshold`) y c (intensidad de poda C4.5). Se diseñó un grid de búsqueda con 24 combinaciones:

$$\alpha \in \{0,50; 0,95\} \times \beta \in \{0,00; 0,01; 0,10\} \times c \in \{0,01; 0,05; 0,10; 0,25\}$$

Para cada combinación se entrena RuleCOSI+ sobre `X_train_cosi` usando el CatBoost entrenado como modelo base, y se evalúa el F1-score sobre `X_test`. Este procedimiento se aplica de forma idéntica en los dos escenarios definidos.

4.3 Escenarios de Evaluación

Se definen dos escenarios con el fin de cuantificar el impacto del data leakage:

Escenario A (referencia): el dataset incluye recoveries durante todo el pipeline. CatBoost se entrena con esta variable presente. Replica, en términos generales, el entorno del trabajo de Jaramillo et al. (2024). Los resultados de este escenario ilustran cómo el leakage distorsiona la extracción de reglas.

Escenario B (definitivo): recoveries se elimina antes de cualquier entrenamiento. CatBoost se reentrena sin esta variable. Es el escenario metodológicamente correcto y el que se adopta como contribución principal de este trabajo.

Comentado [ELA41]: llamar a la tabla de abajo

Comentado [D42R41]: Corregido: ahora dice (Tabla 1) y la tabla de abajo lleva ese título.

Comentado [ELA43]: poner título en todas las tablas y llamarlas desde el texto

Comentado [D44R43]: Se agregaron títulos a las seis tablas (Tabla 1–6) y todas se llaman ahora desde el texto.

4.4 Selección de la Configuración Óptima: Frontera de Pareto

Existe una tensión intrínseca entre la compresión del modelo (pocas reglas, REDU alto) y el rendimiento predictivo (F1 alto): reducir demasiado el número de reglas implica perder capacidad de discriminación. Para resolver esta tensión de forma objetiva, se construye la frontera de Pareto en el espacio (n_{reglas} , $F1_{\text{test}}$) (Deb, 2001; Miettinen, 1999).

Un punto es Pareto-óptimo si no existe otra configuración que lo domine simultáneamente en ambas dimensiones (menos reglas y mayor F1). Una vez identificados los puntos Pareto-óptimos, se selecciona el punto situado inmediatamente por encima del codo de la curva: el codo es el punto donde la ganancia marginal de F1 cae más abruptamente al aumentar el número de reglas. Este criterio favorece el equilibrio entre compresión e interpretabilidad, descartando el tramo donde añadir reglas adicionales aporta rendimiento despreciable.

Comentado [ELA45]: poner referencias

Comentado [D46R45]: Referencias agregadas: (Deb, 2001; Miettinen, 1999).

4.5 Traducción Conceptual a Términos Lingüísticos

Como último paso metodológico se define un procedimiento para traducir las reglas crisp resultantes a términos lingüísticos, con el fin de ilustrar cómo podrían integrarse en un FIS de Mamdani. El procedimiento consta de tres pasos: (1) identificar las variables que aparecen en las condiciones de las reglas seleccionadas; (2) asignar a cada umbral numérico una etiqueta lingüística interpretable (e.g., ALTO, MODERADO, BAJO), coherente con el dominio crediticio; y (3) reexpresar cada regla como una proposición SI-ENTONCES en lenguaje natural. Las reglas finalmente seleccionadas y su traducción lingüística se presentan en la Sección 5.

Esta traducción es conceptual y no constituye un FIS implementado. Su objetivo es mostrar que el resultado de RuleCOSI+ es directamente compatible con la semántica de los sistemas difusos.

4.6 Implementación

El código de la solución se organiza en un único script principal (main.py) que implementa el pipeline completo: carga de datos, preprocesamiento, eliminación de recoveries, partición anti-leakage, entrenamiento de tres modelos base, selección de CatBoost, evaluación sobre X_{test} , y entrenamiento e inferencia de RuleCOSI+ con la configuración Pareto-óptima. El notebook `cosi_experimental_grid_v3.ipynb` implementa el grid de búsqueda de 24 configuraciones y genera la frontera de Pareto en los dos escenarios.

Comentado [ELA47]: poner la dirección al repositorio git

5. Resultados y Discusión

5.1 Escenario A: Grid de Búsqueda con recoveries

El Escenario A replica el entorno del trabajo de Jaramillo et al. al incluir recoveries en el dataset. La Tabla 2 resume los resultados representativos del grid para los valores de α y β más informativos (c varía pero no produce diferencias significativas en n_reglas para este escenario).

Tabla 2. Resultados representativos del grid de búsqueda en el Escenario A (con recoveries).

α (conf)	β (cov)	n_reglas	F1-score	% vs CatBoost	REDU
0,50	0,00	30	0,8835	99,7 %	0,9900
0,50	0,01	4	0,8810	99,4 %	0,9987
0,50	0,10	3	0,8691	98,0 %	0,9990
0,95	cualquiera	0	0,0000	0,0 %	1,0000

El hallazgo más revelador del Escenario A es que ninguna configuración con $\alpha = 0,95$ produce reglas activas. Esto se explica porque la única condición con confianza $\geq 0,95$ en el CatBoost entrenado con recoveries es "IF recoveries > 0,005 THEN class = 1" (confianza = 1,0, cobertura = 0,143). Al elevar el umbral de confianza por encima de este valor, todas las reglas que no involucran recoveries son descartadas. Cuando β filtra también esa regla (por ser post-hoc), no queda ninguna regla válida. Este comportamiento confirma que recoveries domina la estructura del modelo de Jaramillo et al. de forma artificial.

5.2 Escenario B: Rendimiento del Modelo Base y Grid de Búsqueda sin recoveries

El CatBoost entrenado en Escenario B (sin recoveries, sobre X_train_base con 913.122 muestras) alcanzó los indicadores que resume la Tabla 3:

Tabla 3. Rendimiento del modelo base CatBoost en el Escenario B (sin recoveries).

Métrica	Valor
F1-score (validación interna)	0,7740
Umbral óptimo	0,40
Número de árboles (early stopping)	17
Profundidad	5
Reglas teóricas (17×2^5)	544
Reglas activas (cobertura > 0)	332

El early stopping terminó el entrenamiento en 17 iteraciones con learning_rate = 1 sobre una validación interna del 30 %. El modelo resultante tiene 544 hojas teóricas (17×2^5), de las

Comentado [ELA48]: terminar esta sección con la reducción de las reglas bien mostrada, y presentar allí las cinco reglas finales.

Comentado [D49R48]: Hecho: la sección de resultados (5.3) cierra ahora con la reducción 332→5 (REDU = 0,9849) y presenta las cinco reglas finales con sus etiquetas lingüísticas, en formato de lista.


Comentado [ELA50]: jaramillo et al.

Comentado [D51R50]: Corregido: "Jaramillo et al.".

Comentado [ELA52]: mejor organizar todo en resultados del Escenario A y luego resultados del Escenario B

Comentado [D53R52]: Reorganizado: los resultados van ahora Escenario A (5.1) y luego Escenario B (5.2), que integra el modelo base y el grid sin recoveries.

cuales 332 tienen al menos un ejemplo de cobertura en X_{train_cosi} . Este es el conjunto de reglas baseline sobre el que se calcula REDU. La Figura 1 ilustra la magnitud de la reducción alcanzada frente a este baseline.



Comentado [ELA54]: se ve muy pequeño el texto, mejor dividir en dos gráficos.

Figura 1. Reducción de reglas: CatBoost baseline (332 reglas) vs. RuleCOSI+ con la configuración seleccionada (5 reglas). El panel derecho muestra el número de reglas por configuración del grid; verde = cumple umbral $F1 \geq 85\%$ del CatBoost. En el Escenario B, CatBoost se reentrena eliminando recoveries antes de cualquier entrenamiento. El early stopping converge en 17 iteraciones, alcanzando un F1-score de validación de 0,7740 y un umbral óptimo de 0,40. El descenso de F1 con respecto al CatBoost de Jaramillo et al. (0,7740 vs. 0,8887) cuantifica el componente espurio que recoveries aportaba al proceso de aprendizaje: sin ella, el modelo trabaja exclusivamente con variables disponibles en el momento de la decisión crediticia. La Tabla 4 presenta los resultados representativos del grid en este escenario.

Tabla 4. Resultados representativos del grid de búsqueda en el Escenario B (sin recoveries).

α (conf)	β (cov)	c	n_reglas	F1-score	% vs CatBoost	REDU
0,50	0,10	cualquiera	2	0,7591	98,1 %	0,9940
0,50	0,01	0,10	5	0,7652	98,9 %	0,9849
0,50	0,00	0,10	23	0,7671	99,1 %	0,9307
0,95	cualquiera	cualquiera	0–1	< umbral 85 %	0–32,1 %	$\geq 0,9970$

La diferencia crítica respecto al Escenario A aparece en la fila de $\alpha = 0,95$: en el modelo limpio, el umbral de alta confianza extrae como máximo una regla, con un F1 de apenas 0,2486 (32,1 % del CatBoost base), muy por debajo del umbral mínimo aceptable del 85 %. Esto indica que el modelo de 17 árboles entrenado sin recoveries no desarrolla condiciones con confianza $\geq 0,95$ que sean suficientemente informativas para cubrir el espectro completo de clases, en contraposición al Escenario A donde sí existía una —la condición sobre recoveries—, que precisamente era la única razón de ese alto valor de confianza. La configuración definitiva de este trabajo es $\alpha = 0,50$, $\beta = 0,01$, $c = 0,10$, que produce 5 reglas basadas íntegramente en variables crediticias legítimas. La Figura 2 presenta el heatmap de métricas para las 24 configuraciones del grid.




Figura 2. Heatmap de métricas del grid de 24 configuraciones (Escenario B): número de reglas (izq.), F1-score en test (centro) y condiciones promedio por regla (der.), para cada combinación de α , β y c .

5.3 Frontera de Pareto y Configuración Seleccionada

A partir de los resultados del Escenario B se identifican tres puntos Pareto-óptimos en el espacio (n_reglas , $F1_test$), que se detallan en la Tabla 5:

Tabla 5. Puntos Pareto-óptimos en el espacio (n_reglas , $F1_test$).

Punto	n_reglas	F1-score	REDU	$F1 \times REDU$	α	β	c
P1 (codo)	2	0,7591	0,9940	0,7546	0,50	0,10	cualquiera
P2 ★	5	0,7652	0,9849	0,7536	0,50	0,01	0,10
P3	23	0,7671	0,9307	0,7140	0,50	0,00	0,10




Figura 3. Frontera de Pareto en el espacio (n_reglas , $F1_test$). Los rombos rojos son los tres puntos Pareto-óptimos; los círculos azules son configuraciones no dominantes. P1 es el codo de la curva; P2 (5 reglas, $F1=0,7652$) es el punto seleccionado.

Como se aprecia en la Figura 3, el salto de P1 a P2 —de 2 a 5 reglas— recupera 0,0061 puntos de F1 a cambio de solo 3 reglas adicionales. El salto siguiente, de P2 a P3 —de 5 a 23 reglas— apenas aporta 0,0019 puntos de F1 adicionales a un costo de 18 reglas más: la ganancia

Comentado [ELA55]: hacer los gráficos más grandes, no se ve el texto

Comentado [ELA56]: no olvidarnos que toda figura y tabla debe estar mencionada en el texto.

Comentado [D57R56]: Verificado: las seis tablas y las tres figuras quedan mencionadas explícitamente en el texto.

Comentado [ELA58]: poner título a todos los gráficos y tablas

Comentado [D59R58]: Listo: las seis tablas tienen título; las tres figuras ya contaban con pie (Figura 1–3).

marginal cae un 95 %. P1 es el codo natural de la curva; P2 es el punto inmediatamente superior al codo, donde todavía se obtiene rendimiento relevante por cada regla agregada.

La configuración seleccionada es P2: $\alpha = 0,50$, $\beta = 0,01$, $c = 0,10$, que produce 5 reglas con $F1 = 0,7652$ y $REDU = 0,9849$. Esta configuración retiene el 98,9 % del rendimiento del CatBoost original comprimiendo el modelo de 332 a 5 reglas activas. Nótese que si se aplicara el criterio $\max(F1 \times REDU)$, se elegiría P1 ($0,7546 > 0,7536$); la elección de P2 refleja una decisión deliberada de priorizar el equilibrio entre compresión e interpretabilidad sobre la optimización puramente matemática de ese producto.

La configuración seleccionada produce cinco reglas crisp; el número no se fija a priori, sino que emerge de la poda de RuleCOSI+ con $\alpha = 0,50$, $\beta = 0,01$ y $c = 0,10$ sobre las 332 reglas activas del CatBoost base. Las condiciones de estas cinco reglas involucran únicamente cuatro variables —las que sobreviven a la simplificación—: `last_fico_range_high` (límite superior del último rango FICO reportado), `fico_range_low` (límite inferior del rango FICO actual), `loan_amnt` (monto del préstamo) y `debt_settlement_flag` (indicador binario de acuerdo de liquidación de deuda). Aplicando el procedimiento de traducción descrito en la Sección 4.5, los umbrales numéricos se etiquetan lingüísticamente así:

1. `last_fico_range_high > 681,5` se etiqueta como "FICO RECIENTE es ALTO" (historial crediticio sólido).
2. `last_fico_range_high > 596,5` se etiqueta como "FICO RECIENTE es ACEPTABLE" (historial básicamente positivo).
3. `last_fico_range_high ≤ 626,5` se etiqueta como "FICO RECIENTE es BAJO" (historial crediticio deteriorado).
4. `fico_range_low > 647,5` se etiqueta como "FICO ACTUAL es BUENO" (rango de crédito vigente en buen estado).
5. `loan_amnt > 8.862,5` se etiqueta como "MONTO es ALTO".
6. `loan_amnt ≤ 14.812,5` se etiqueta como "MONTO es MODERADO".
7. `debt_settlement_flag ≤ 0,5` se etiqueta como "SIN acuerdo de liquidación" (el prestatario no ha formalizado ningún acuerdo de reestructuración de deuda).

Con estas etiquetas, las cinco reglas finales —y la regla por defecto— se expresan de la siguiente manera:

- R0: SI FICO ACTUAL es BUENO Y FICO RECIENTE es ALTO Y SIN acuerdo de liquidación → buen pagador ($\text{conf} = 0,99$; cubre el 56,8 % de los casos).
- R1: SI FICO ACTUAL es BUENO Y FICO RECIENTE es BAJO Y MONTO es ALTO → impago probable ($\text{conf} = 0,71$; cubre el 17,4 %).
- R2: SI FICO ACTUAL es BUENO Y FICO RECIENTE es ACEPTABLE Y SIN acuerdo de liquidación Y MONTO es MODERADO → buen pagador ($\text{conf} = 0,90$; cubre el 12,5 %).
- R3: SI FICO ACTUAL es BUENO Y FICO RECIENTE es ACEPTABLE Y SIN acuerdo de liquidación → buen pagador ($\text{conf} = 0,85$; cubre el 6,7 %).
- R4: SI FICO ACTUAL es BUENO Y FICO RECIENTE es BAJO → impago probable ($\text{conf} = 0,60$; cubre el 5,9 %).
- REGLA POR DEFECTO: impago probable (cubre el 0,7 % restante).

5.4 Discusión

La Tabla 6 compara los tres enfoques evaluados en este trabajo y en el de Jaramillo et al. (2024):

Comentado [ELA60]: llevarlo a la sección de discusión

Comentado [D61R60]: Hecho: la comparación con Jaramillo et al. se fusionó con la Discusión (ahora 5.4), que abre con la Tabla 6 y los dos contrastes y cierra con las implicaciones.

Tabla 6. Comparación de enfoques: este trabajo frente a Jaramillo et al. (2024).

Enfoque	n_reglas	F1-score	% vs CatBoost propio	recoveries incluida
CatBoost Jaramillo et al. (con leakage)	—	0,8887	100 %	Sí
FIS Mamdani — Jaramillo et al.	717	0,4963	55,8 %	Sí
CatBoost limpio (Escenario B)	—	0,7740	100 %	No
RuleCOSI+ P2 — Este trabajo	5	0,7652	98,9 %	No

Los resultados revelan dos contrastes fundamentales. Primero, el FIS de Jaramillo et al. incurre en una pérdida de F1 del 44,2 % respecto a su propio CatBoost de referencia (de 0,8887 a 0,4963). Esta pérdida es atribuible a la combinación de: (a) la alta dimensionalidad del espacio de reglas (717 reglas de 25 árboles), (b) la discretización imprecisa de las variables continuas en conjuntos difusos sin optimización, y (c) el manejo del umbral de decisión en la defuzzificación. En contraste, RuleCOSI+ reduce el modelo de 332 a 5 reglas perdiendo únicamente 1,1 % de F1 (de 0,7740 a 0,7652).

Segundo, la comparación entre el CatBoost de Jaramillo et al. (F1 = 0,8887, con recoveries) y el CatBoost limpio de este trabajo (F1 = 0,7740, sin recoveries) indica que la variable post-hoc recoveries inflaba artificialmente el rendimiento en 0,1147 puntos de F1. Esta diferencia no refleja capacidad predictiva genuina sino una dependencia espuria aprendida por el modelo de Jaramillo et al.: cuando recoveries = 0 (valor de todas las solicitudes nuevas en producción), el modelo de Jaramillo et al. pierde su principal ancla de clasificación. Las cinco reglas del Escenario B, al basarse exclusivamente en variables crediticias disponibles en el momento de la solicitud (puntaje FICO, monto del préstamo, indicador de acuerdo de liquidación), son operacionalmente válidas y desplegadas en un entorno de producción real.

Los resultados de este trabajo tienen tres implicaciones prácticas relevantes. Primera, la reducción de 332 a 5 reglas (REDU = 0,9849) con pérdida mínima de rendimiento representa un equilibrio favorable entre interpretabilidad y precisión: cinco reglas pueden ser revisadas, validadas y comunicadas por analistas de riesgo sin herramientas especializadas, mientras que 332 reglas requieren técnicas avanzadas de explicabilidad. Segunda, la corrección del data leakage no solo es metodológicamente necesaria sino que también tiene implicaciones regulatorias: un modelo que utiliza recoveries en producción estaría tomando decisiones basadas en información que aún no existe, lo que podría constituir una violación de requisitos de equidad y transparencia en sistemas de crédito. Tercera, la comparación directa con el FIS de Jaramillo et al. muestra que la fuzzificación, aplicada sin optimización de funciones de membresía, puede degradar severamente el rendimiento. La extracción de reglas crisp mediante RuleCOSI+ ofrece una alternativa más robusta que puede complementarse con una fuzzificación cuidadosamente calibrada en trabajos futuros.

6. Conclusiones

Este trabajo abordó el problema de la interpretabilidad en modelos de scoring crediticio de alto rendimiento, con el objetivo de extraer reglas comprensibles a partir de un CatBoost entrenado sobre el dataset de LendingClub. Los resultados permiten formular las siguientes conclusiones:

1. Extracción eficiente de reglas crisp con retención de rendimiento casi completa.

La configuración Pareto-óptima seleccionada ($\alpha = 0,50$, $\beta = 0,01$, $c = 0,10$) produce cinco reglas crisp con un F1-score de 0,7652 sobre el conjunto de prueba, lo que representa el 98,9 % del rendimiento del CatBoost de referencia (F1 = 0,7740). La Reducción de Reglas es REDU = 0,9849: el modelo pasa de 332 reglas activas a 5, manteniendo casi toda su capacidad predictiva.

2. Corrección de una fuga de información presente en el trabajo previo de Jaramillo et al. (2024).

La variable recoveries es post-hoc: su valor solo se conoce después de producido el incumplimiento. Al eliminarla antes de cualquier entrenamiento, el modelo aprende exclusivamente de variables disponibles en el momento de la decisión crediticia. El Escenario A (con recoveries) confirma el problema: con $\alpha = 0,95$, ninguna regla se extrae porque la única condición de alta confianza involucra recoveries y, al filtrarla, no queda ninguna regla activa. El Escenario B (sin recoveries) demuestra que sin la variable espuria el modelo construye cinco reglas basadas en indicadores crediticios legítimos (FICO, monto del préstamo, historial de liquidaciones). Este hallazgo tiene relevancia directa para la aplicabilidad de los modelos en producción y para el cumplimiento de marcos regulatorios de explicabilidad.

3. Superioridad del enfoque RuleCOSI+ frente al FIS de Mamdani en la tarea evaluada.

El FIS de Mamdani implementado en el trabajo de Jaramillo et al. (2024) perdió el 44,2 % del F1-score del modelo base al construir 717 reglas difusas desde 25 árboles. El enfoque de este trabajo, que extrae 5 reglas crisp desde 17 árboles mediante RuleCOSI+, pierde únicamente el 1,1 %. Esta diferencia sugiere que la pérdida en el trabajo de Jaramillo et al. no se debe a una limitación inherente del paradigma difuso, sino a las decisiones de diseño del FIS (número de árboles fuente, funciones de membresía sin optimización, umbral de defuzzificación). Las cinco reglas crisp obtenidas aquí son directamente traducibles a términos lingüísticos difusos, lo que hace factible construir un FIS de alta precisión como extensión futura.

4. La frontera de Pareto como herramienta objetiva de selección.

La construcción explícita de la frontera de Pareto en el espacio (n_reglas, F1_test) permitió identificar tres configuraciones no dominadas y seleccionar P2 como el punto de mayor equilibrio mediante el criterio del codo: pasar de 2 a 5 reglas recupera 0,0061 de F1 adicional (ganancia relevante); pasar de 5 a 23 reglas solo aporta 0,0019 de F1 con 18 reglas adicionales (ganancia marginal despreciable). Este procedimiento puede aplicarse directamente a otros problemas de extracción de reglas donde se busque equilibrar compresión y rendimiento.

5. Limitaciones de la investigación.

Los resultados deben interpretarse considerando varias limitaciones. Primero, el estudio se basa en un único dataset (LendingClub, mercado estadounidense), por lo que la generalización de las reglas a otras carteras o contextos regulatorios no está garantizada. Segundo, la traducción lingüística de las reglas es conceptual: no se implementó ni validó un FIS ejecutable, de modo que la viabilidad de un sistema difuso de alta precisión construido sobre estas reglas permanece como hipótesis. Tercero, la comparación con Jaramillo et al. (2024) está condicionada por diferencias de configuración entre ambos trabajos (número de árboles fuente y esquemas de partición), por lo que las brechas reportadas combinan el efecto

Comentado [ELA62]: pongamos los límites de la investigación antes de las recomendaciones.

Comentado [D63R62]: Hecho: se agregó el numeral 5 'Limitaciones de la investigación' antes de las recomendaciones (Trabajo futuro, ahora numeral 6).

del método y el de dichas diferencias. Finalmente, la selección de la configuración óptima mediante el criterio del codo depende del grid explorado; otros espacios de búsqueda podrían producir fronteras de Pareto distintas.

6. Trabajo futuro.

Las extensiones naturales de este trabajo incluyen: (a) fuzzificación calibrada de las cinco reglas crisp mediante optimización de funciones de membresía con datos históricos, para construir un FIS de alta precisión; (b) validación del pipeline en otros datasets de crédito (e.g., German Credit, Give Me Some Credit) para evaluar la generalización; (c) incorporación de restricciones de equidad (fairness) en el proceso de selección de reglas; y (d) exploración de técnicas de explicabilidad post-hoc (SHAP, LIME) complementarias a las reglas crisp para usuarios no técnicos.

En síntesis, esta tesis demuestra que es posible comprimir un modelo CatBoost de 332 reglas activas a 5 reglas interpretables, retener el 98,9 % del rendimiento, y hacerlo sobre datos libres de fuga de información. Las cinco reglas resultantes son auditables, comunicables a reguladores y desplegables en un entorno de producción real, lo que las convierte en una herramienta concreta para la toma de decisiones crediticias transparente y responsable.

7. Referencias

Con formato: Inglés (Estados Unidos)

- [1] L. Obregón y A. Jung, "RuleCOSI+: Rule Extraction Algorithm for Accurate and Interpretable Classification", *Expert Systems with Applications*, vol. 216, pp. 119–432, 2023. <https://doi.org/10.1016/j.eswa.2022.119432>
- [2] A. V. Dorogush, V. Ershov, y A. Gulin, "CatBoost: gradient boosting with categorical features support", *arXiv:1810.11363*, 2018. <https://arxiv.org/abs/1810.11363>
- [3] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye y T.-Y. Liu, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree", en *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 3149–3157, 2017.
- [4] T. Chen y C. Guestrin, "XGBoost: A Scalable Tree Boosting System", en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 785–794, 2016. <https://doi.org/10.1145/2939672.2939785>
- [5] L. Breiman, "Random Forests", *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. <https://doi.org/10.1023/A:1010933404324>
- [6] E. Bauer y R. Kohavi, "An Empirical Comparison of Voting Classification Algorithms: Bagging, Boosting, and Variants", *Machine Learning*, vol. 36, no. 1–2, pp. 105–139, 1999. <https://doi.org/10.1023/A:1007515423169>
- [7] B. Jaramillo, "Extracción de Reglas Difusas desde Árboles de Decisión para Scoring Crediticio", Tesis de Maestría, Universidad San Francisco de Quito, 2024.
- [8] L.-A. Zadeh, "Fuzzy sets", *Information and Control*, vol. 8, no. 3, pp. 338–353, 1965. [https://doi.org/10.1016/S0019-9958\(65\)90241-X](https://doi.org/10.1016/S0019-9958(65)90241-X)
- [9] E. H. Mamdani y S. Assilian, "An experiment in linguistic synthesis with a fuzzy logic controller", *International Journal of Man-Machine Studies*, vol. 7, no. 1, pp. 1–13, 1975. [https://doi.org/10.1016/S0020-7373\(75\)80002-2](https://doi.org/10.1016/S0020-7373(75)80002-2)
- [10] LendingClub Corporation, "LendingClub Loan Data", Kaggle, 2020. <https://www.kaggle.com/datasets/wordsforthewise/lending-club>
- [11] Comisión Europea, "Reglamento sobre Inteligencia Artificial (AI Act)", *Diario Oficial de la Unión Europea*, 2024. <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32024R1689>

Con formato: Inglés (Estados Unidos)

- [12] L. C. Thomas, J. N. Crook y D. B. Edelman, *Credit Scoring and Its Applications*, 2.^a ed., SIAM, 2017. <https://doi.org/10.1137/1.9781611974560>
- [13] D. J. Hand y W. E. Henley, "Statistical Classification Methods in Consumer Credit Scoring: a Review", *Journal of the Royal Statistical Society: Series A*, vol. 160, no. 3, pp. 523–541, 1997. <https://doi.org/10.1111/j.1467-985X.1997.00078.x>
- [14] E. I. Altman, "Financial Ratios, Discriminant Analysis and the Prediction of Corporate Bankruptcy", *The Journal of Finance*, vol. 23, no. 4, pp. 589–609, 1968. <https://doi.org/10.1111/j.1540-6261.1968.tb00843.x>
- [15] J. C. Wiginton, "A Note on the Comparison of Logit and Discriminant Models of Consumer Credit Behavior", *Journal of Financial and Quantitative Analysis*, vol. 15, no. 3, pp. 757–770, 1980. <https://doi.org/10.2307/2330408>
- [16] S. Lessmann, B. Baesens, H.-V. Seow y L. C. Thomas, "Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research", *European Journal of Operational Research*, vol. 247, no. 1, pp. 124–136, 2015. <https://doi.org/10.1016/j.ejor.2015.05.030>
- [17] B. Gunnarsson, S. vanden Broucke, B. Baesens, M. Óskarsdóttir y W. Lemahieu, "Deep learning for credit scoring: Do or don't?", *European Journal of Operational Research*, vol. 295, no. 1, pp. 292–305, 2021. <https://doi.org/10.1016/j.ejor.2021.03.006>
- [18] B. Baesens, T. Van Gestel, S. Viaene, M. Stepanova, J. Suykens y J. Vanthienen, "Benchmarking state-of-the-art classification algorithms for credit scoring", *Journal of the Operational Research Society*, vol. 54, no. 6, pp. 627–635, 2003. <https://doi.org/10.1057/palgrave.jors.2601545>
- [19] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush y A. Gulin, "CatBoost: unbiased boosting with categorical features", en *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 6638–6648, 2018.
- [20] R. Kohavi y C.-H. Li, "Oblivious Decision Trees, Graphs, and Top-Down Pruning", en *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 1071–1077, 1995.
- [21] C. Rudin, "Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead", *Nature Machine Intelligence*, vol. 1, no. 5, pp. 206–215, 2019. <https://doi.org/10.1038/s42256-019-0048-x>

- [22] S. Guillaume, "Designing fuzzy inference systems from data: An interpretability-oriented review", IEEE Transactions on Fuzzy Systems, vol. 9, no. 3, pp. 426–443, 2001. <https://doi.org/10.1109/91.928739>
- [23] K. Deb, Multi-Objective Optimization Using Evolutionary Algorithms, Wiley, 2001.
- [24] K. Miettinen, Nonlinear Multiobjective Optimization, Kluwer Academic Publishers, 1999.
- [25] Comité de Supervisión Bancaria de Basilea, "Basel III: Finalising post-crisis reforms", Banco de Pagos Internacionales, 2017. <https://www.bis.org/bcbs/publ/d424.htm>
- [26] J. Obregón, A. Kim y J.-Y. Jung, "RuleCOSI: Combination and simplification of production rules from boosted decision trees for imbalanced classification", Expert Systems with Applications, vol. 126, pp. 64–82, 2019. <https://doi.org/10.1016/j.eswa.2019.02.012>